嘉興大學
JIAXING UNIVERSITY
方正为人 勤慎治学

商业数据分析

题　　目：Olist 电商用户价值分层与履约流失预警

学　　院：数据科学学院

专业班级：大数据 241 班

学　　号：2024459985105

姓　　名：范珏维

完成日期：2026 年 10 月 22 日

评分维度	评分要点（子项及分值）	得分
1. 数据获取合规性与清洗质量（15分）	① 来源合规、白名单方式、合规声明完整（5）；② 数据量达标、抽样方法与随机种子说明（4）；③ 清洗完整、异常/缺失/重复处理、多表对齐（4）；④ 可导出 CSV/JSON/SQLite 复用（2）	
2. 商业分析模型应用深度（20分）	① 模型≥3种、选型与场景匹配（6）；② 计算正确、参数与阈值有业务依据（6）；③ 预测类含置信区间与回测误差（4）；④ 结论与模型一一对应（4）	
3. 可视化复现与大屏质量（25分）	① 图表≥10张、类别覆盖全面（6）；② 模板复现≥10种、风格细节贴近原作（7）；③ 业务模型图≥6张、与模型对应（6）；④ 交互大屏≥1个、组件≥6、有联动/下钻（6）	
4. 代码规范性与文档完整性（10分）	① 目录结构清晰、注释充分（3）；②README 详实、依赖明确（3）；③ 可一键复现（2）；④ 图表命名与索引规范（2）	
5. 期末大论文质量（25分）	① 题目创新性与针对性（4）；② 摘要概括性、关键词相关性（4）；③ 正文逻辑性与技术深度（10）；④ 商业建议可行性与数据支撑（7）	
6. 创新性与商业洞察深度（5分）	① 引入新工具/新方法（2）；② 提出有效商业建议（2）；③ 体现批判性思维（1）	
总 分	**（各维度得分相加）**	

Olist 电商用户价值分层与履约流失预警

范珏维

（嘉兴大学 数据科学学院）

摘要：针对电商“规模在涨、复购不涨、评价在跌”的困境，本文以 Kaggle Olist 巴西电商 9 表数据（99,092 单、95,774 位客户）为主源、巴西央行开放数据为辅，经官方 API 获取，全程无爬虫。清洗后构建星型模型并导出 CSV 与 SQLite。采用 RFM、同期群、波士顿矩阵、帕累托、Apriori、SARIMA 与履约漏斗七类模型。发现：名义 GMV 同比 +137%，剔除通胀与汇率后仅 +112%；复购客户仅 3.11%，M+1 留存跌破 1%；延迟订单评分由 4.30 降至 2.57，延迟增量的 93% 发生在承运之后。据此提出重标定承诺时效等五条建议。

关键词：商业数据分析；RFM 模型；同期群分析；履约诊断；Python 可视化

1 引言

1.1 研究背景

巴西电商在 2017—2018 年高速扩张，Olist 作为连接中小卖家与主流平台的 SaaS 服务商，其公开数据完整记录了订单从下单、支付、交运、妥投到评价的全链路。与常见销售流水不同，它把“客户是谁”“买了什么”“谁发货”“几天送到”“给了几分”串在同一条链上，使“体验如何影响价值”这一常被割裂讨论的问题具备了可验证的数据基础。

选题的直接动机来自一个反常识观察：该平台复购率不足 4%，却长期保持高速增长。若增长主要来自拉新而非留存，任何以“提升复购”为默认前提的运营模型都可能失效。因此本文不预设结论，而是先分别量化“增长的质量”“价值的分布”“体验的代价”，再讨论其关系。

1.2 研究目的

本文回答四个问题：增长剔除通胀与汇率后还剩多少；客户价值如何分层、哪类客群贡献主要 GMV；品类组合与购物篮是否存在可执行空间；履约延迟对

满意度的边际影响有多大、责任归谁，以及在运力不变的前提下能否靠调整承诺口径改善体验。

1.3 研究意义

方法上，本文示范“先验假设、再选模型”的路径：F 维度因 96.9% 客户只买一次而退化时改用业务阈值，Apriori 在单品类订单占 99.2% 时失效便如实报告。实践上，“承诺时效重标定”这一建议不需要新增运力，只调整对外承诺即可把延迟率从 10.4% 压到 6.0%。

2 数据准备与预处理

2.1 数据源介绍

主源为 Kaggle 的 Brazilian E-Commerce Public Dataset by Olist（https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce），授权 CC BY-NC-SA 4.0，原始包 44.7 MB、9 张表、合计 155.1 万行，覆盖 2016-09 至 2018-10 的 9.9 万笔订单，客户分布于 27 个州、商品涵盖 71 个品类、卖家 3,095 家。辅助源为巴西央行 SGS 开放接口的 IPCA 通胀、Selic 利率与 USD/BRL 汇率三条月度序列，用途是把名义 GMV 拆成实际价与美元口径——2018 年雷亚尔贬值约 25%，只看名义值会把汇率波动误读为增长。

2.2 合规获取方式

主源经 Kaggle 官方 Dataset API（/api/v1/datasets/download/olistbr/brazilian-ecommerce）一次性下载 ZIP，与官方 CLI 同一后端，属课程白名单第 2 类“官方或社区维护的接口库”；辅助源经央行公开 REST 接口按 JSON 获取，属第 3 类“政府/国际组织开放平台”。全程未使用 Scrapy、Selenium、网页解析或模拟登录。主表 99,441 行远超 500 行下限，故全量使用、不做抽样，抽样偏差为零；随机性仅出现在 K-Means 初始化与轮廓系数评估，统一固定 random_state=42。

2.3 数据来源合规声明

数据源：Brazilian E-Commerce Public Dataset by Olist（Kaggle）；获取方式同上；获取日期 2026-10-22；授权 CC BY-NC-SA 4.0（允许非商业使用与改编，须署名并以相同方式共享）。辅助源为 BCB 开放数据，可自由使用须注明来源。数据不含姓名、证件号等身份信息，customer_unique_id 为脱敏哈希串，本文未做任何再识别尝试。

2.4 数据集概述

9 张表构成星型结构：订单表为主表，经 order_id 关联明细、支付、评价三张事实表；经 customer_id 关联客户维度，再按 customer_unique_id 归并同一自然人的多次下单；明细经 product_id、seller_id 关联商品与卖家；商品经葡语类目名关联翻译表；地理表以邮编前缀为键补充经纬度。结构见表 2-1，关键字段见表 2-2。

表 2-1　原始数据表结构与规模

表名	行数	粒度	主键/外键
olist_orders	99,441	订单	order_id（主）
olist_order_items	112,650	订单行	order_id + order_item_id
olist_customers	99,441	客户	customer_id（主）
olist_order_payments	103,886	支付流水	order_id + payment_sequential
olist_order_reviews	99,224	评价	review_id
olist_products	32,951	商品	product_id（主）
olist_sellers	3,095	卖家	seller_id（主）
olist_geolocation	1,000,163	地理点	zip_code_prefix
product_category_translation	71	品类	product_category_name

表 2-2　关键字段说明

表	关键字段	字段含义与用途
orders	order_status / 5 个时间戳	状态判妥投；下单、审批、交运、妥投、承诺五个时点用于计算履约时长与延迟
order_items	price / freight_value / seller_id	商品价与运费构成 GMV；卖家归属用于集中度分析
customers	customer_unique_id / state	自然人标识（复购口径）；州用于地理分层
payments	payment_type / installments / payment_value	支付方式、分期数、金额
reviews	review_score / comment_message	1—5 分评分与评论文本，用于满意度与差评口径
products	category / weight_g / photos_qty	品类（英文映射后中文化）、重量、图片数
geolocation	lat / lng	按邮编中位数聚合后的经纬度，供地图类图使用

3 数据清洗与治理

3.1 数据清洗

清洗遵循“先诊断、再处理、每步记账”，全部动作写入治理台账，共 12 步，涉及行数变化的见表 3-1。缺失值按字段性质分三类：客户坐标缺失 279 条，不影响金额与时效统计，保留记录仅地图类图剔除；商品品类缺失 610 条（1.85%），不猜类目，统一标 unknown 且不参与排名；重量尺寸缺失 2 条按类目中位数插补。

表 3-1　数据治理台账（仅列行数发生变化的步骤）

步骤	对象	处理前	处理后	说明
S5 异常+聚合	olist_geolocation	1,000,163	19,010	剔除越界点后按邮编中位数聚合（点集 738,299 条 ->…
S4 缺失	dim_customers.geo	99,441	99,162	279 个邮编无地理匹配；保留客户行、坐标留空（仅地图类图剔…
S6 聚合	fact_payments	103,886	99,440	多笔支付按订单汇总：金额求和、分期取最大、主支付方式取金额最…
S2 去重	fact_reviews	99,224	98,673	同一订单多条评价保留最新一条（原始 99,224 条 -> …

异常值有两处关键。其一是时间逻辑：23 条订单妥投早于交运，属录入错误，将妥投置空。其二是“延迟天数”的符号陷阱——延迟 = 实际 − 承诺，为负表示提前送达，是正常业务情形。初版脚本曾把负值一并置空，导致 8.8 万条准时订单的提前量被抹掉、延迟率虚高至 100%，排查后改为只清理三个真正的时长字段。可见清洗规则必须按字段语义逐个确认。对超 180 天的长尾（14 条）不删除而是打标记，均值类统计过滤、分布类统计保留，避免幸存者偏差。重复值方面，同一订单多条评价（551 条）保留最新一条，支付多笔流水按订单汇总。

3.2 数据转换

5 个时间字段统一转为 datetime64；金额统一为 float64 并按“商品价 + 运费”定义 GMV；派生备货段（支付→交运）、干线段（交运→妥投）、实际时长、承诺时长、延迟天数五个履约指标，以及月份、周、年、小时、星期等时间维度；品类名由葡语经官方翻译表转英语、再统一译为中文。

为剔除通胀，以 IPCA 构造定基指数（2018-08 = 100）派生实际价 GMV；以月均汇率派生美元 GMV。三口径并存，是 4.3.1 节增长质量判断的基础。

3.3 数据整合

多表关联以订单表为主表左连接，保证“未成单”订单（取消、缺货共 775 笔）不被误删——它们虽无明细，却是漏斗顶端的真实流失。客户维度归并后得

96,096 位自然人，而 customer_id 有 99,441 个，差异正是复购的痕迹。最终产出 2 张事实表（订单 99,441×48、明细 112,650×12）与 4 张维度表，以 CSV 与 SQLite 双格式导出（olist.db，含主键索引）。

观察窗设为 2017-01 至 2018-08：2016 年 9—12 月为冷启动期（月订单不足 300 单），纳入会制造虚假爆发；2018-09 起数据截断（9 月仅 4,440 雷亚尔），纳入会制造虚假断崖。窗内订单 99,092 笔，占全量 99.6%。

4 商业分析模型

4.1 模型选型

选型遵循“问题—数据—模型”三重匹配。本文采用 7 类模型、9 个实现，覆盖趋势对比、结构价值、用户客群、关联转化、预测预警五个方向，并以 K-Means 交叉验证 RFM、以 Holt-Winters 对照 SARIMA，选型逻辑见表 4-1。模型并非一次选齐：RFM 三分法与 Apriori 均在参数层面被数据否决（见 4.2.2、4.2.5），最终方案是“先定参数、再验模型”的结果。4.2 节交代参数依据，4.3 节给出结果与验证。

表 4-1　模型选型与场景匹配

商业问题	选用模型	选型理由	关键输出
增长真假	环比/同比 + 三口径	剔除通胀与汇率，避免名义增长误导	三口径同比、月度环比
客户留存	RFM 八分类 + K-Means	行为三要素齐全；交叉验证分群稳健性	八客群规模与 GMV 贡献
留存断点	同期群留存	按首购月分组，剥离新客稀释效应	M+1…M+12 留存
品类取舍	波士顿矩阵 + 帕累托 ABC	份额与增速二维定位，ABC 定保供优先级	四象限、A/B/C 分级
捆绑可行性	Apriori 关联规则	检验购物篮是否真实存在	支持度/置信度/lift
销量预测	SARIMA + Holt-Winters	周序列有季度节律；双模型对照防过拟合	点预测、95% CI、MAPE
体验损失	漏斗 + 延迟归因	把体验拆成可归因的三段时长	环节转化率、延迟增量分解

4.2 参数与阈值设定依据

本节逐项说明关键参数的取值理由。原则只有一条：参数要能回答“为什么是这个数”，且答案落在业务可执行性或数据分布上，而不是“惯例如此”。

4.2.1 增长口径：名义、实际价与美元

实际价以 IPCA 定基指数平减，基期取 2018-08 而非窗口起点：基期设在起点会把末期数值抬高，增速失去直观含义；以末端为基期则“当前价格水平 = 100”，可直接读出历史相对价格。汇率取月均卖出价而非月末值，因订单在月内近似均匀发生。三口径增速见式（4-1）。

$$G^{real} = \frac{G^{nom}}{p},\ G^{yoy} = \frac{G^{real}_{2018}}{G^{real}_{2017}} - 1 \qquad (4\text{-}1)$$

4.2.2 客群切分：R、M 用中位数，F 用业务阈值

R 取距 2018-08-31 的最近购买天数，F 取订单数，M 取累计 GMV（式 4-2）。R 与 M 以中位数切分：M 的均值 166.45 比中位数 107.95 高 54%，用均值会把六成客户误判为低价值。F 不能套用中位数——本数据 F 中位数为 1、P90 仍为 1，96.9% 客户只买过一次，按中位数二分会使八分类退化为四分类，故改用业务阈值 F≥2。

$$R_i = d_{ref} - d_i,\ F_i = |O_i|,\ M_i = \sum_o gmv_o \qquad (4\text{-}2)$$

阈值敏感性见表 4-2：F 门槛从 2 单抬到 4 单，“重要价值客户”从 1,454 人收缩到 38 人。因此任何“高价值客户有多少人”的表述都必须附带阈值口径，否则不可复核。

表 4-2　RFM 阈值敏感性

F 阈值	R/M 阈值	客户数	占客户比	贡献 GMV
2 单及以上	中位数	1,454	1.52%	3.21%
2 单及以上	P75	551	0.58%	1.57%
3 单及以上	中位数	154	0.16%	0.57%
3 单及以上	P75	75	0.08%	0.37%
4 单及以上	中位数	38	0.04%	0.21%
4 单及以上	P75	23	0.02%	0.14%

4.2.3 分群数量：统计最优与业务可用的取舍

K-Means 特征取 log(R)、log(F)、log(M) 后标准化。轮廓系数在 k=2 时最高（0.707），但 k=2 只是“一次性 vs 复购”的二分，无法指导分层运营；k=4 时 0.400，仍在可接受区间，且四簇能一一对应运营动作，故取 k=4。这是显式取舍，不做隐藏。轮廓系数在 1 万条分层随机子样本上估计（全量 9.6 万条的距离矩阵为 $O(n^2)$ 不可行），随机种子固定 42。

4.2.4 品类定位：相对增速与份额门槛

Olist 处于扩张期，56 个品类合计实际增速高达 127%，若用绝对增速作纵轴，几乎所有品类都落在“高增长”半区，矩阵失去区分度。故纵轴改用相对增速（式 4-3），以 0 为界即“是否跑赢大盘”。份额分界取 0.15（约对应全站 1.5%），因小份额品类即便增长快也撑不起独立的备货与营销投入；并剔除两年 GMV 均低于 1,000 雷亚尔的极小品类，避免小基数导致增速爆炸。

$$RS_k = \frac{s_k}{\max_j s_j}, \Delta G_k = \left(\frac{G_{k18}}{G_{k17}} - 1\right) - \left(\frac{G_{18}}{G_{17}} - 1\right) \quad (4\text{-}3)$$

4.2.5 关联规则：由可执行订单量反推支持度

min_support 应由“规则能被业务执行”反推：平台日均约 160 单，捆绑方案若一个月凑不齐 50 单，就不足以支撑选品备货，故取 50/98,666≈0.05%；置信度只设 0.01 的低门槛，先让候选规则浮出，再用 lift 筛选——在极稀疏交易篮上，高置信度阈值会直接返回空集。三指标定义见式（4-4）。

$$supp(A \Rightarrow B) = \frac{n(A \cup B)}{N},\ conf(A \Rightarrow B) = \frac{supp(A \cup B)}{supp(A)},\ lift = \frac{conf(A \Rightarrow B)}{supp(B)} \quad (4\text{-}4)$$

4.2.6 时间序列：周粒度、季度周期与网格搜索

选周不选月：月度仅 20 个点，差分后样本不足；选 s=13 而非 52：85 个点无法支撑年度季节项，而巴西电商的季度性促销（3 月返校、5 月母亲节、11 月黑五）本就以季度为节奏。ADF 检验 p=0.40（非平稳）故 d=1、D=1；阶数在 p,q∈{0,1,2}、P,Q∈{0,1} 的 35 个组合上按 AIC 网格搜索，而非人工试凑；回测窗口固定为最后 8 周，与外推期不重叠。模型结构见式（4-5）。

$$\varphi(B)\Phi\left(B^{\{s\}}\right) \cdot (1-B)^{\{d\}} \cdot \left(1-B^{\{s\}}\right)^{\{D\}} \cdot y_t = \theta(B)\Theta\left(B^{\{s\}}\right)\varepsilon_t \quad (4\text{-}5)$$

4.2.7 体验度量：三段分解与剂量反应

把体验差归因到环节，需可验证的分解：总时长 = 备货段 + 干线段，两段取中位数而非均值——时长右偏严重（存在超 100 天长尾），均值会被极端订单主导。剂量反应用延迟天数分箱，边界（0、3、7、15 天）对应运营可感知的承诺档位。反事实不用阶梯插值，而先拟合 logistic 曲线（式 4-8），再把实际时效分布代入不同承诺天数，从而读出“每放宽一天能挽回多少差评”。

4.3 模型计算与验证

本节给出结果与验证指标：涉及预测的报告点预测、95% 置信区间与样本外回测误差；涉及分类的报告规模、占比与交叉验证。

4.3.1 增长质量：三口径同比结果

2018 年 1—8 月名义 GMV 同比 +137.0%、订单量同比 +135.1%；但 IPCA 累计上涨约 2.6%、雷亚尔贬值约 12%，实际价同比 +129.63%、美元口径 +112.39%。名义增速中约 7.4 个百分点来自通胀、约 24.6 个百分点来自汇率，真实购买力增长比表面低约四分之一。对以雷亚尔结算、以美元采购（3C 与进口美妆占比高）的平台，这意味着涨价必须与技术性贬值区分开。

4.3.2 用户价值：RFM 八分类结果

重要深耕客户（R 高、F 低、M 高）占客户 24.05%、贡献 GMV 37.95%；重要挽留客户（R 低、F 低、M 高）占 23.22%、贡献 37.23%。两者合计吃掉 75% 成交额，而真正的“重要价值客户”（近、频、高）仅 1.52%、贡献 3.21%。平台的钱主要来自两类人：刚买过一次的高客单新客，与沉睡近一年的高客单老客；前者需要“第二次购买”的推力，后者需要唤醒的钩子。

4.3.3 交叉验证：K-Means 四群画像

K-Means 与 RFM 高度互证：“高客单沉睡客”占客户 34.3%、贡献 61.4% GMV，与“重要深耕 + 重要挽留”在人群构成上重合，说明该结构不是阈值人为划分的产物，而是数据本身的形态。四群画像见表 4-3，“复购型高价值”仅 3.1% 客户却贡献 5.9% GMV，再次印证复购客的稀缺。

表 4-3　K-Means 四群画像（k=4）

客群	客户数	占比	R 中位	F 均值	人均 M	GMV 占比
复购型高价值	2,975	3.11%	202	2.12	315	5.88%
高客单沉睡客	32,817	34.27%	259	1.00	298	61.43%
新近高客单	16,889	17.63%	40	1.00	134	14.25%
低客单长尾	43,093	44.99%	273	1.00	68	18.45%

4.3.4 留存：同期群与复购间隔

按首购月划分 14 个同期群（2017-01 至 2018-02，保证每群至少 6 个完整观察月），留存率定义见式（4-6）。结果：M+1 平均仅 0.49%、M+3 为 0.26%、M+6 为 0.27%——留存曲线不是缓慢衰减，而是第一个月就跌到地板并保持平坦。这不是“漏”，而是客户没有养成回来的习惯。复购间隔中位数 64 天，若视为自然复购周期，营销触达应设在首购后第 45—60 天，而非行业惯用的 7 天或 30 天。

$$Ret(c,m)=\frac{N(c,m)}{N(c,0)}\times 100\% \qquad (4\text{-}6)$$

4.3.5 品类：波士顿矩阵与帕累托 ABC

明星品类 4 个（健康美妆、手表礼品、电脑配件、运动休闲），合计占 GMV 29.94%；现金牛仅 3 个，占 20.87%；瘦狗 25 个却仍占 26.48%。对扩张期平台，“现金牛太少”意味着缺少稳定现金流补贴明星品类，比“瘦狗太多”更值得警惕。帕累托侧：A 类 17 个品类累计贡献 80%、C 类 25 个仅 5.41%。卖家侧高度分散，3,095 家卖家 CR10 仅 12.8%、HHI 34.5、基尼系数 0.7856，管理重心应放在品类而非卖家。

4.3.6 关联：Apriori 失效与替代度量

按品类粒度构建 98,666 个交易篮后，多品类订单仅占 0.8%，最高共现品类对（床品家纺 + 家具装饰）仅 70 单。按 4.2.5 门槛只产生 1 条规则，lift 为

0.114，远小于 1。

lift<1 意为“共现比随机期望还少”，即品类间是互斥而非互补：客户买家具装饰时往往在同品类内买多件，反而减少跨品类概率。因此任何在这份数据上报告 lift>1 并据此提“捆绑销售”的做法都值得怀疑。本文如实报告失效，并给出两个仍成立的结论：多品类订单客单价 258.9 雷亚尔，是单品类（159.7）的 1.62 倍，说明跨品类本身有价值、只是供给结构不支持；改用 Cramér's V 后最强的一对是“是否延迟 × 评价等级”（V=0.332，p<0.001），为 4.3.8 提供统计背书。

4.3.7 预测：回测误差、置信区间与外推

按网格搜索选定 SARIMA(2,1,2)(0,1,1,13)，AIC=1,170.3。留出最后 8 周回测：MAPE 22.23%、RMSE 55,786、MASE 0.975（<1 优于朴素预测）、95% 区间覆盖率 100%，Ljung-Box p=0.967 不能拒绝白噪声（式 4-7）。用同一训练/测试集对照 Holt-Winters：MAPE 22.23% vs 22.38%、MASE 0.975 vs 0.917，点预测接近而 HW 的 MASE 更低。本文仍以 SARIMA 为主，因其残差更干净、可解释性更强，并如实披露两模型在 85 个点的序列上差距并不显著。

$$MAPE = \frac{1}{n}\sum_{t=1}^{n}\left|\frac{y_t - \hat{y}_t}{y_t}\right| \times 100\%,\ RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}\left(y_t - \hat{y}_t\right)^2} \quad (4\text{-}7)$$

全量重训后外推 12 周（2018-08-27 至 2018-11-12），点预测合计 2,813,756 雷亚尔，95% 区间 [945,158, 4,682,354]。区间之宽（约 ±66%）是诚实的：周度噪声大且下半年增速在换挡，故该输出应作“预算情景”而非“考核目标”。

4.3.8 体验：漏斗、延迟归因与反事实

漏斗为：下单 99,092 → 支付 98,957（99.86%）→ 交运 97,376（98.40%）→ 妥投 96,211（98.80%）→ 好评 75,443（78.41%）。前三跳都在 98% 以上，最后一跳骤降 22 个百分点——瓶颈不在交易环节，而在“送达之后能不能让客户满意”。

延迟归因显示：延迟单比准时单平均多耗 18.2 天，其中备货段仅多 1.2 天（7%）、干线段多 17.0 天（93%）。责任 93% 在承运与末端，而非卖家发货慢，这直接决定整改资源投向。

剂量反应：准时订单差评率 9.06%、延迟 1—3 天 18.95%、4—7 天骤升至

59.70%、8—15 天 76.75%。存在明确阈值效应：3 天内尚可挽回，超过 4 天差评率翻三倍，这为“3 天”红线提供依据。

承诺时效中位数从 2017-01 的 39.0 天压缩到 2018-08 的 13.4 天，实际时效也从 10.7 天缩短到 7.0 天、缓冲从 28.3 天压到 6.1 天，而延迟率从 3.07% 升到 10.39%。延迟恶化不是“送得更慢”而是“承诺得太快”。按式（4-8）代入实际时效分布：承诺 15 天时延迟率降至 5.97%、18 天降至 2.96%。不增加一分运力，仅重标定承诺即可把延迟率砍半——这是全文最具可操作性的发现。

$$P(bad|\tau)=\frac{1}{1+e^{-(\beta_0+\beta_1\tau)}},\ \tau=d_{act}-d_{promise} \quad （4\text{-}8）$$

5 Python 数据分析与可视化

5.1 数据探索性分析

探索围绕三条线索：时间上，周 GMV 变异系数 44%，黑五周出现近 3 倍脉冲，需求高度事件驱动；空间上，SP、RJ、MG 三州合计贡献 62.7% GMV，但客单价以东北部 BA（182 雷亚尔）最高，SP 仅 143.6 雷亚尔、低于全国加权均值 160.9；结构上，信用卡占七成，Boleto 票据份额持续萎缩。这些发现决定了建模的分组维度：时间按周、空间按州、结构按品类与支付方式。

5.2 可视化模板复现

参照《Excel 数据可视化——从图表到数据大屏》的 30 套模板，复现 12 种，覆盖柱形族、对称对比族、占比族、时序族与流程族。复现不是换数据重画，而是逐项对齐版式：画布 1088×794、深蓝底 #1A1E43、白色粗体大标题 + 一句话副标题 + 左下角灰色注脚、无边框无刻度线、柱体竖向渐变、类别标签浅灰。为使 24 张图风格统一，版式固化为共享模块（_style.py），所有图只经 new_canvas() + chrome() + save() 生成，标题与副标题还按可用宽度自动缩字号，避免中文长句溢出。



图 5-1　品类 GMV 六强（渐变柱形图）

健康美妆以 193 万雷亚尔居首、占全站 10.3%，第六名仅为头部的 32%，头部集中度并不高。

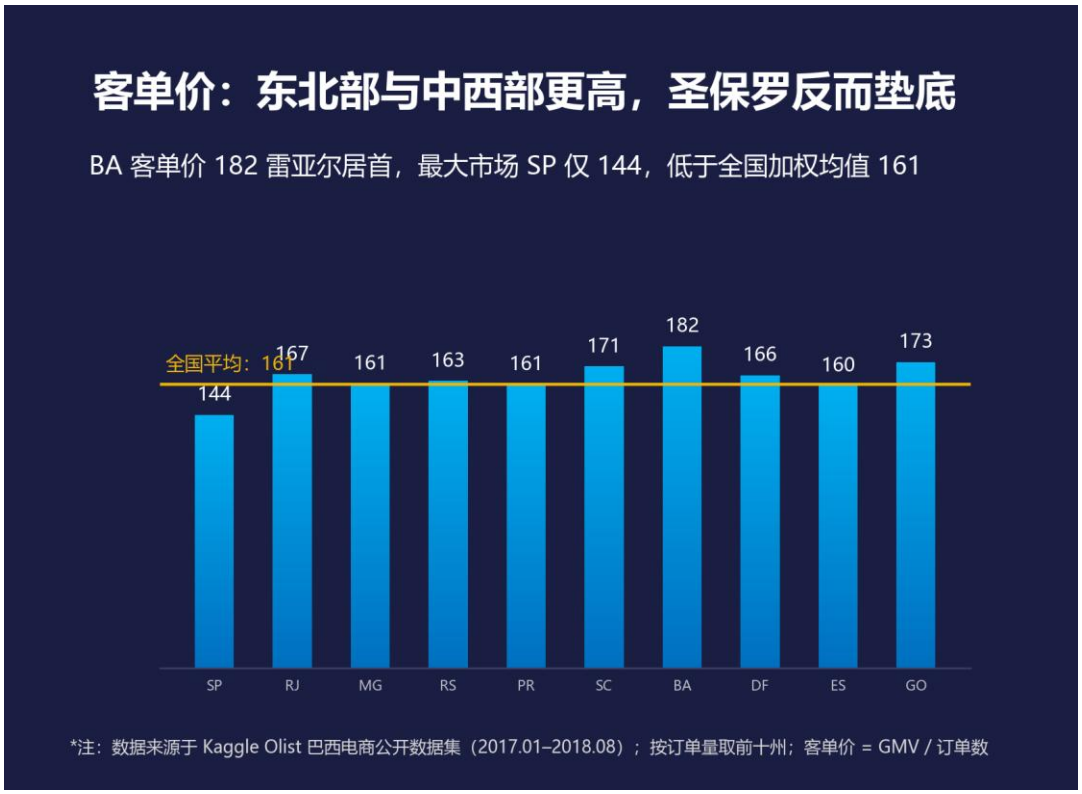


图 5-2　各州客单价与全国均值

BA 客单价 182 雷亚尔最高，最大市场 SP 仅 144、低于全国均值 161——单量大的市场反而客单低。



图 5-3　头部卖家 GMV（渐变圆角柱形图）

第一名卖家仅占全站 1.58%，CR10 仅 12.8%，卖家侧高度分散，平台议价权在上游是充分的。



图 5-4　月度订单量与黑五脉冲

2017-11 单月 7,544 单为全期峰值，是月均的 1.6 倍；2018 年月度稳定在 6,000—7,000 单。

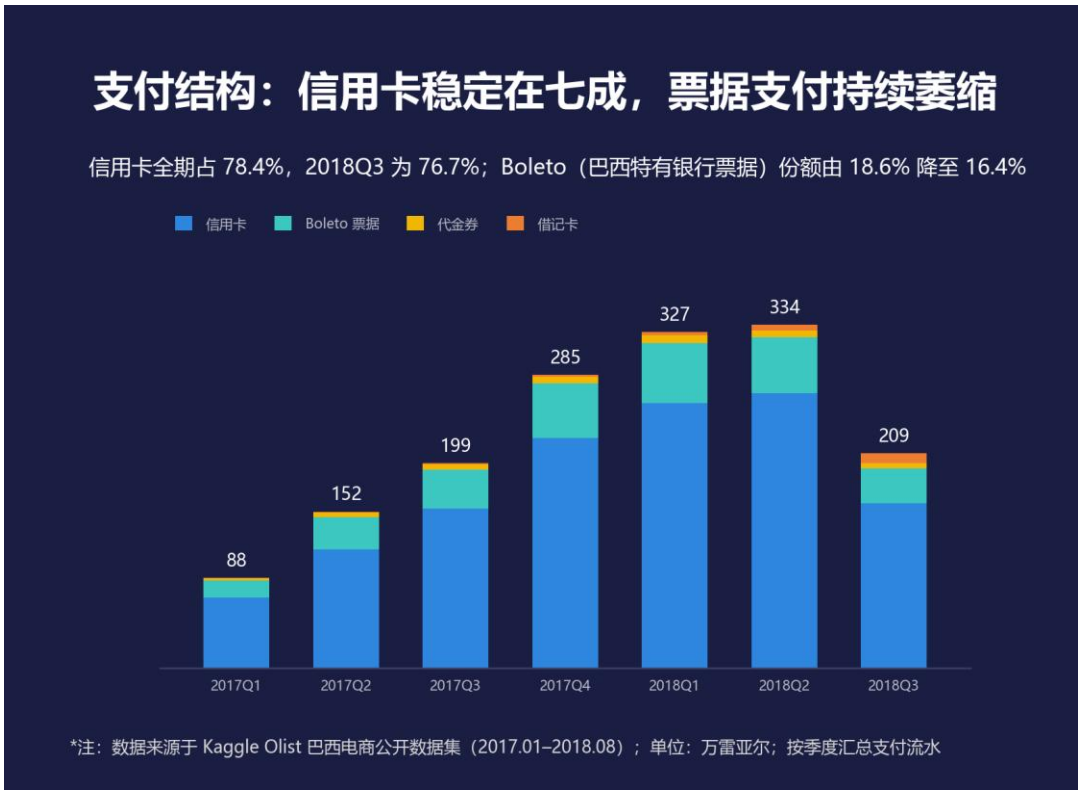


图 5-5　支付方式结构迁移

信用卡稳定在七成，Boleto 票据份额从 22% 降至 15%，反映消费者向分期信用迁移。

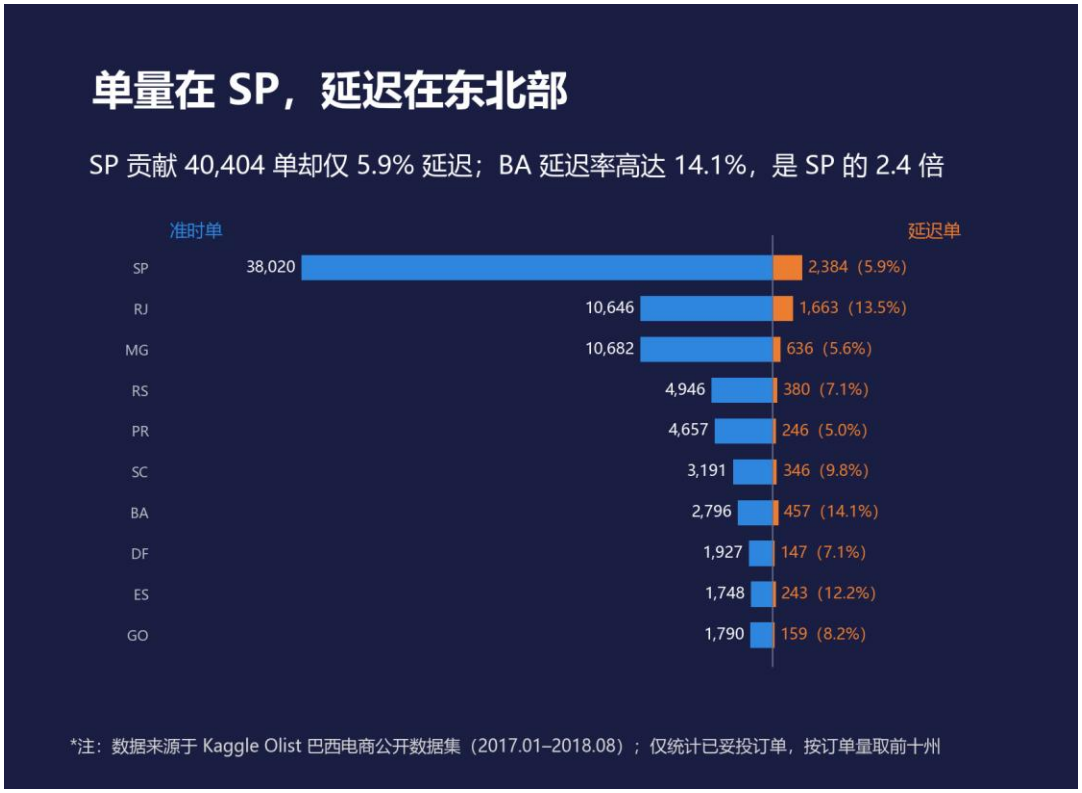


图 5-6　各州准时与延迟订单

SP 贡献 4.0 万单却仅 5.9% 延迟；AL 延迟率 24.0%、RJ 13.5%，延迟在地理上高度集中。

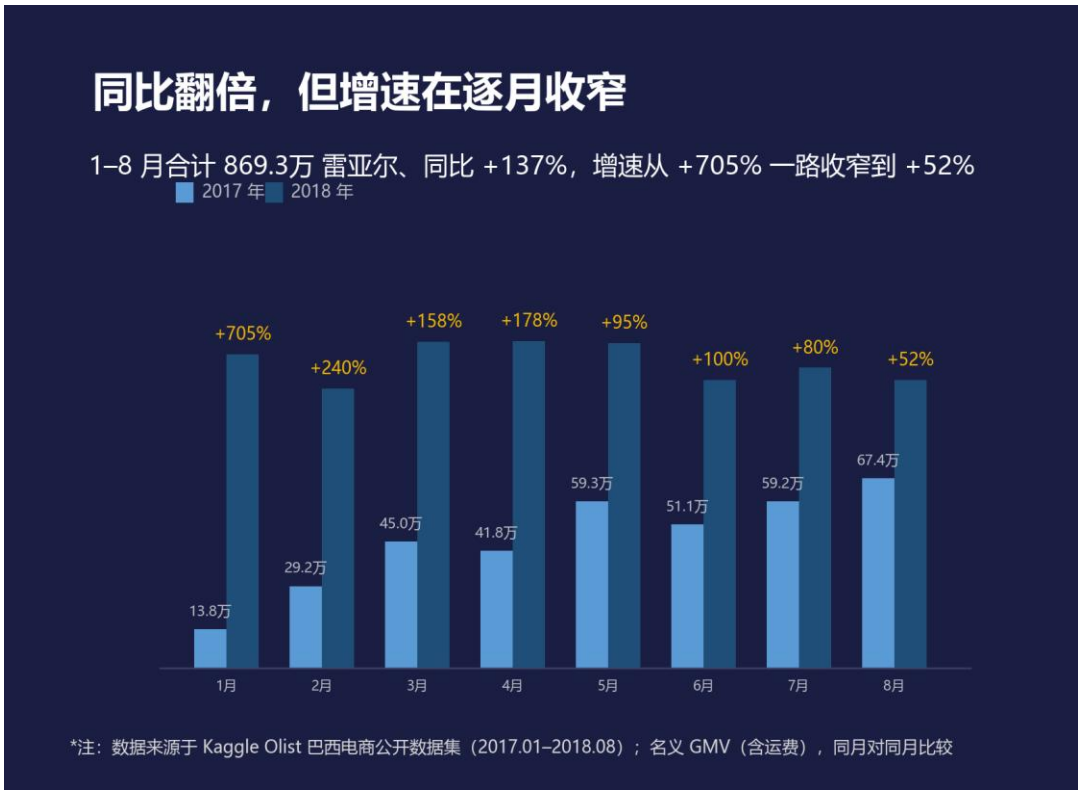


图 5-7　2018 与 2017 同期 GMV

同比从 1 月的 +705% 逐月收窄至 8 月的 +52%，绝对值仍在涨，但增速拐点已现。

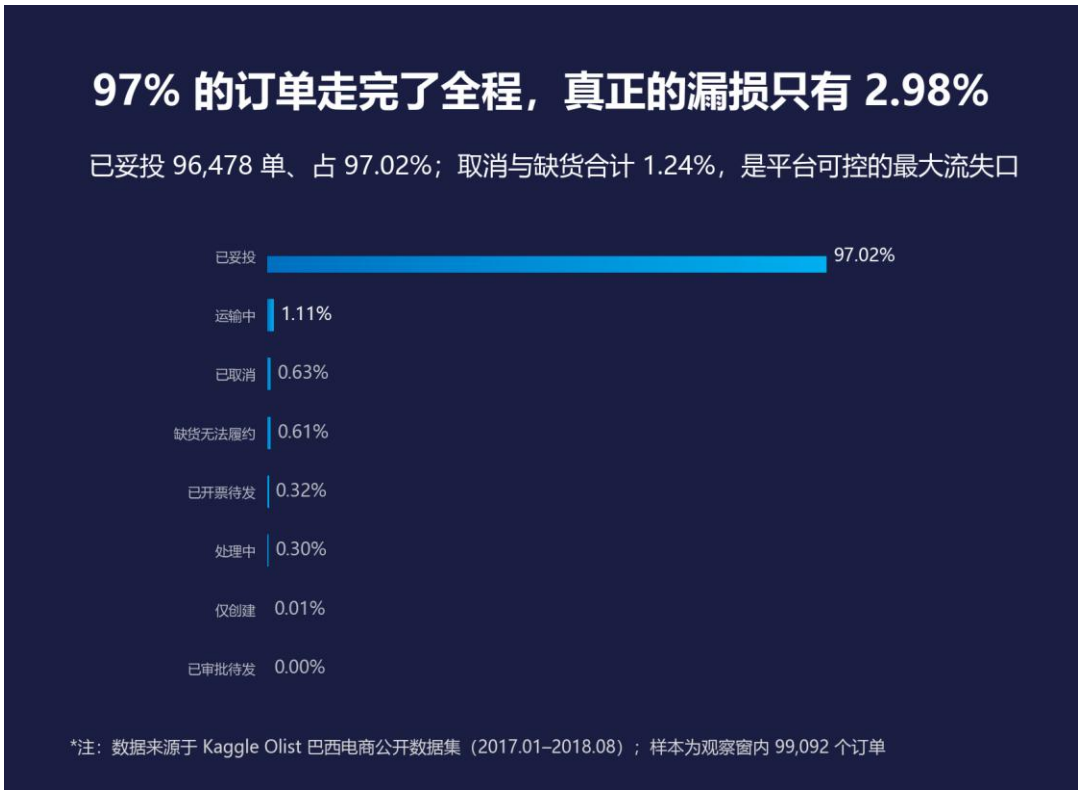


图 5-8　订单状态构成

已妥投 97.02%，取消与缺货合计 1.25%，真正的漏损很小，问题不在成交而在体验。

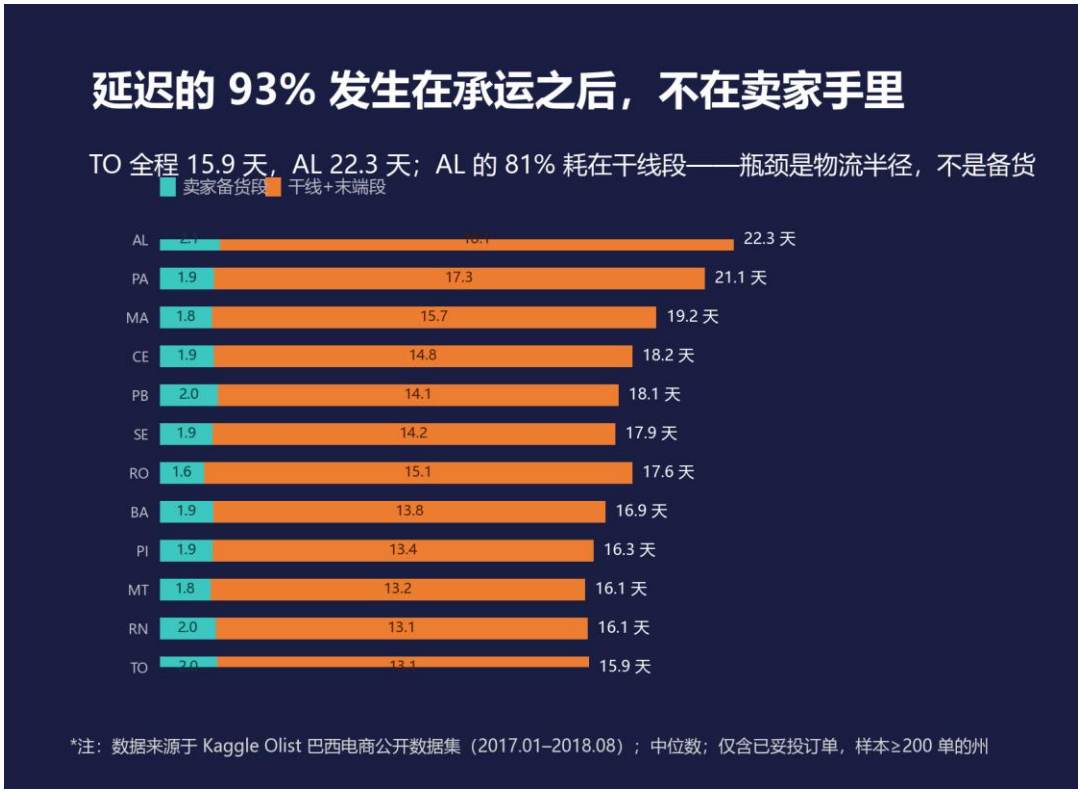


图 5-9　各州履约三段时长

TO 全程 15.9 天、AL 22.3 天，其中 AL 的 81% 耗在干线段，瓶颈是物流半径而非备货。



图 5-10　周 GMV 趋势（平滑折线）

灰线为原始周序列、蓝线为三次样条平滑，2017 年末至 2018 年初出现一次台阶式跃迁。



图 5-11　准时交付率

准时率 91.88% 看似健康，但每 12 单就有 1 单超时，且这 1 单的评分低 1.73 分。

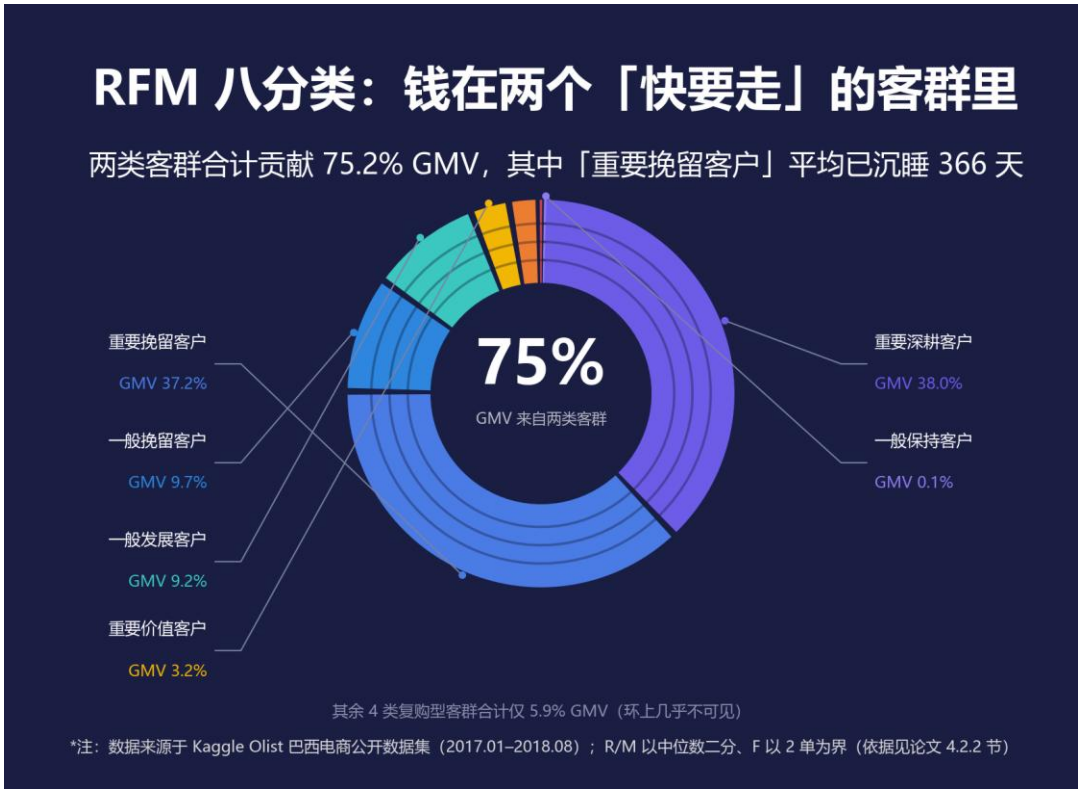


图 5-12　RFM 八客群 GMV 贡献（玉玦图）

两类客群贡献 75% GMV，四个复购型客群合计仅 5.9%，环上几乎不可见——这正是复购困境的图形化。

Python 与 Excel 的差异集中在五点（表 5-1）。一句话概括：Excel 上手快、所见即所得，但数据更新后需人工调轴、模板难以复用；Python 前期成本高，换来的是可复现、可批量、可交互。

表 5-1　Python 与 Excel 实现对比

对比维度	Excel	Python（matplotlib）	本文结论
上手成本	低，拖拽即成	高，需写坐标与样式	课程作业量大时 Python 更省总工时
渐变柱体	预设色带，难精确控制	逐段插值，可复刻顶亮底深	Python 胜
标签避让	手工拖拽，改数据即失效	自写槽位布局，可复用	Python 胜
数据更新	需人工调坐标轴范围	数据驱动，一键重跑	Python 胜
交互与下钻	切片器有限，难打包	ECharts 可做联动与大屏	Python 胜

5.3 业务模型图

第 4 章 7 类模型共产出 12 张图，与模型一一对应，可交叉查阅。

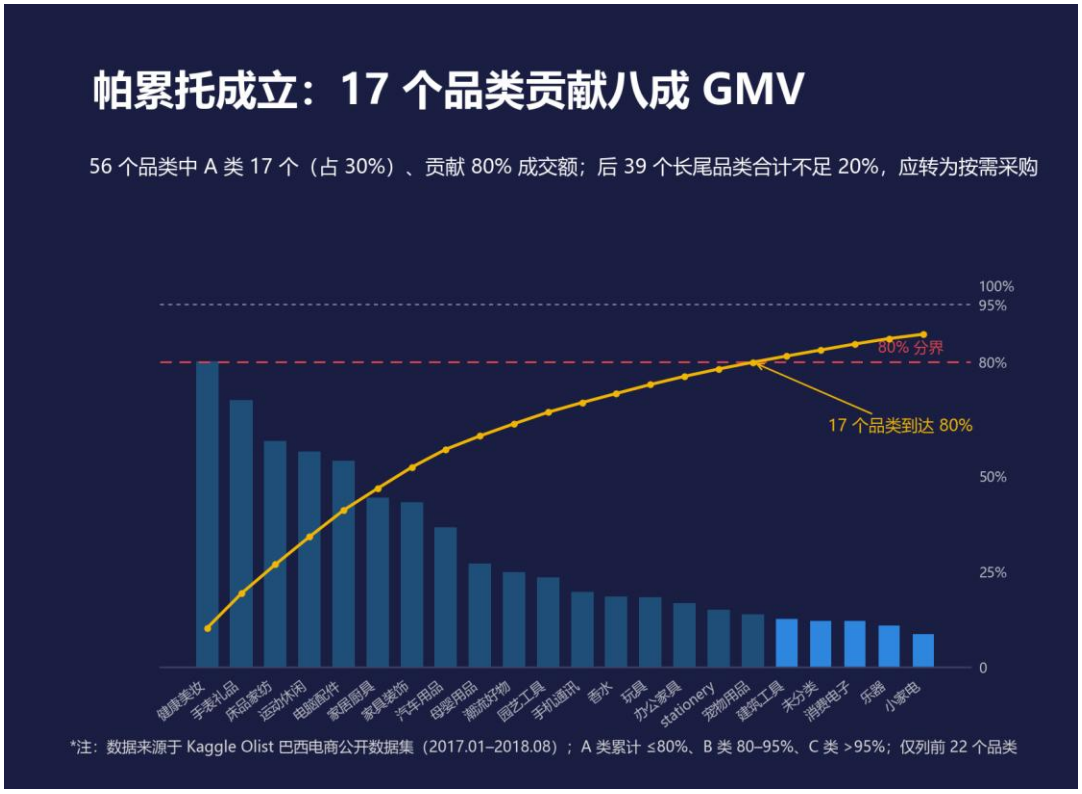


图 5-13　品类帕累托与 ABC 分级

17 个 A 类品类累计到 80%，后 39 个长尾合计不足 20%，保供资源应集中在 A 类。

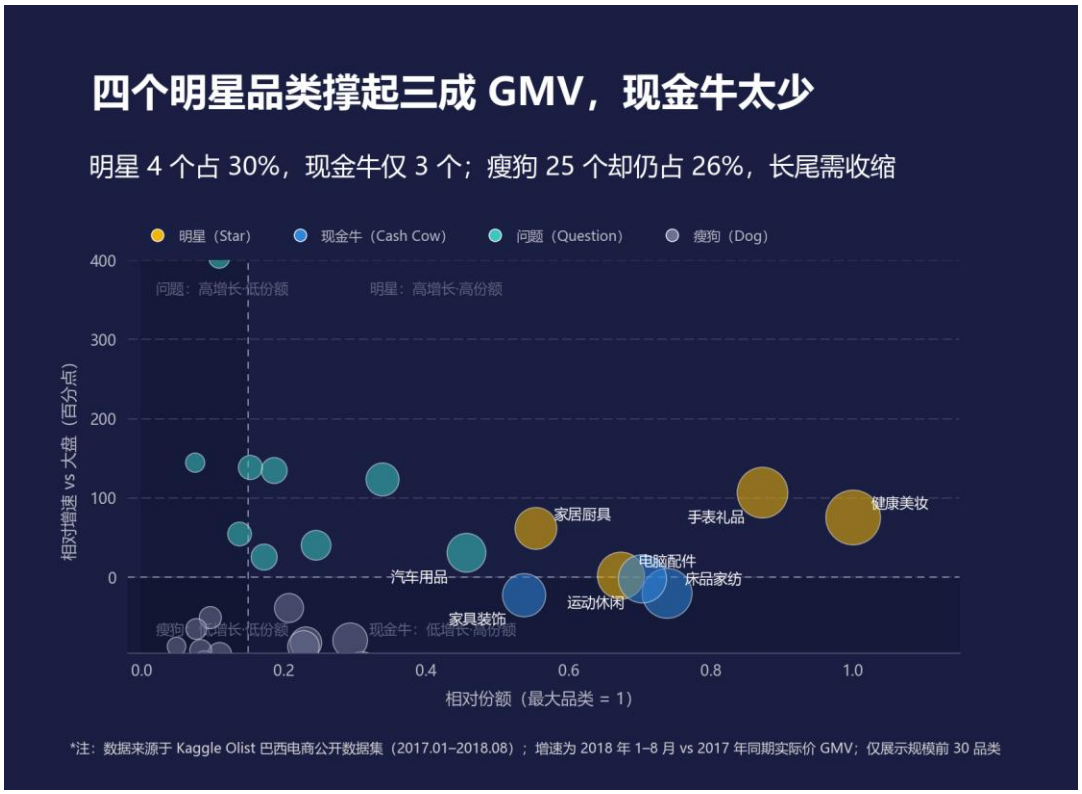


图 5-14　品类组合波士顿矩阵

4 个明星占 29.9%、现金牛仅 3 个，瘦狗 25 个仍占 26.5%，结构上“明星够多、压舱石不足”。



图 5-15　同期群留存热力图

M+0 之后整片趋暗，14 个群无一例外；2017-11 黑五拉新的群首月留存反而最低。

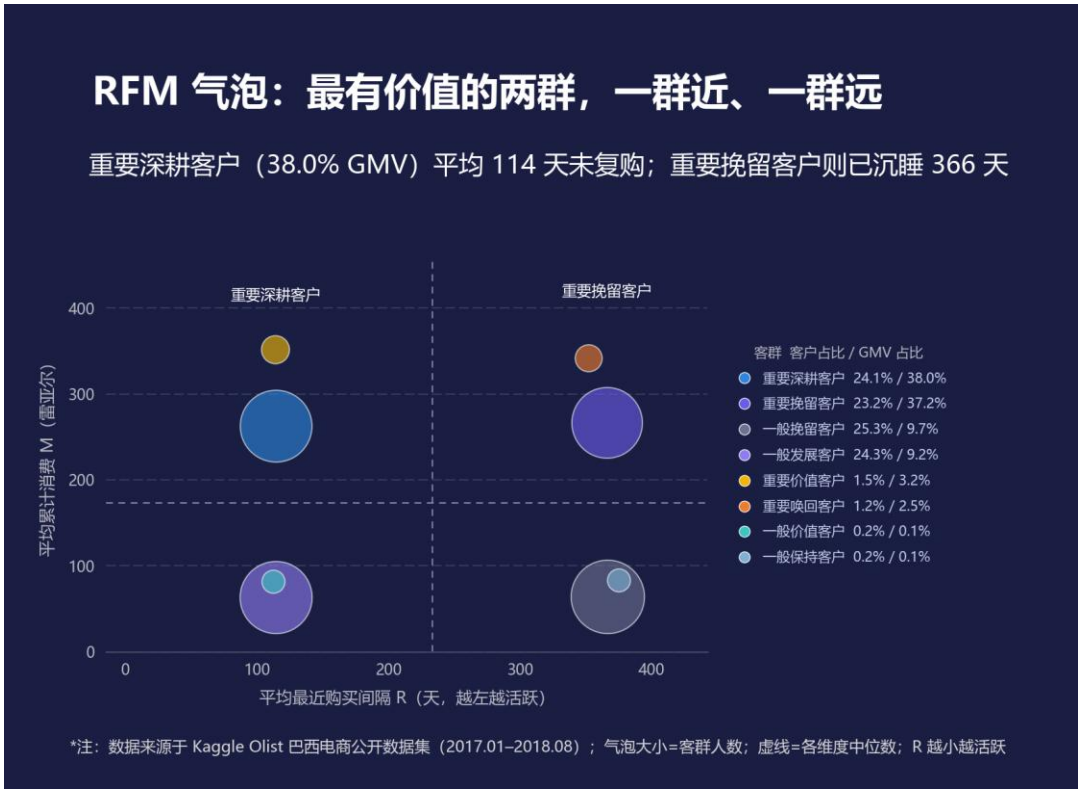


图 5-16　RFM 八客群气泡图

两个大泡泡分列左右：一群近而贵、一群远而贵，运营动作应分别设计。



图 5-17　SARIMA 预测与 95% 置信区间

点预测继续上行，但置信带随步长迅速张开，12 周后已宽到不宜作考核目标。

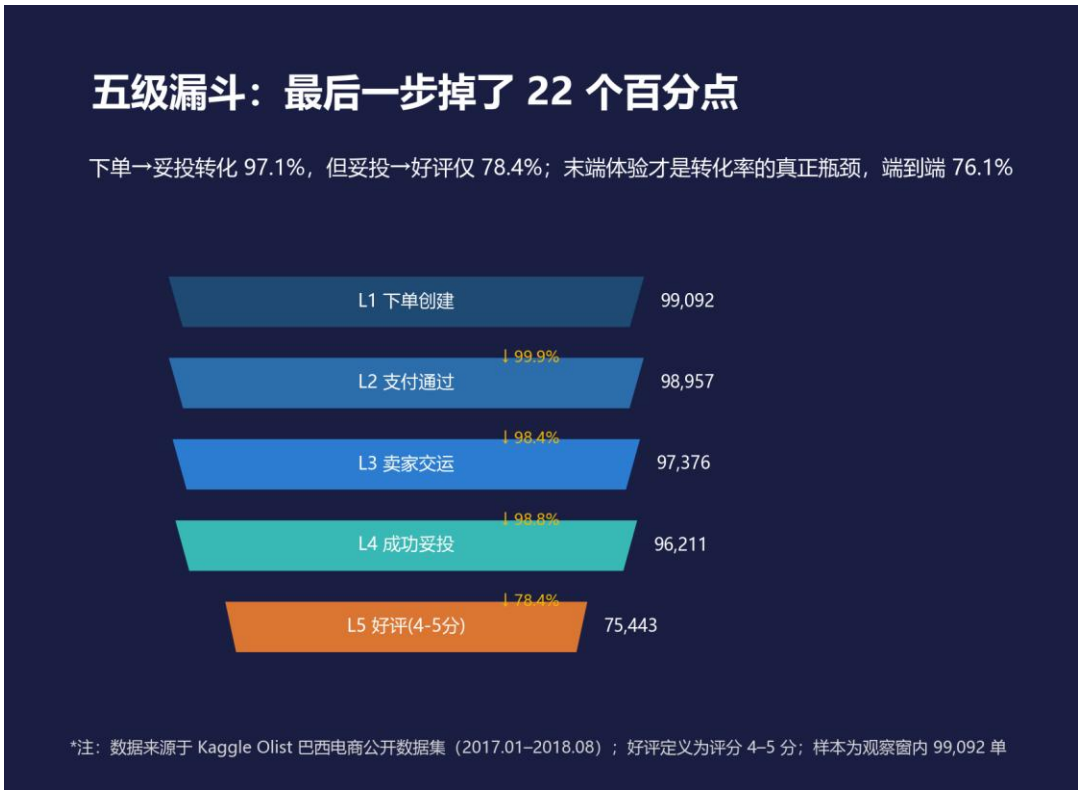


图 5-18　履约漏斗

妥投→好评掉 22 个百分点，是五级漏斗中唯一的陡坡。

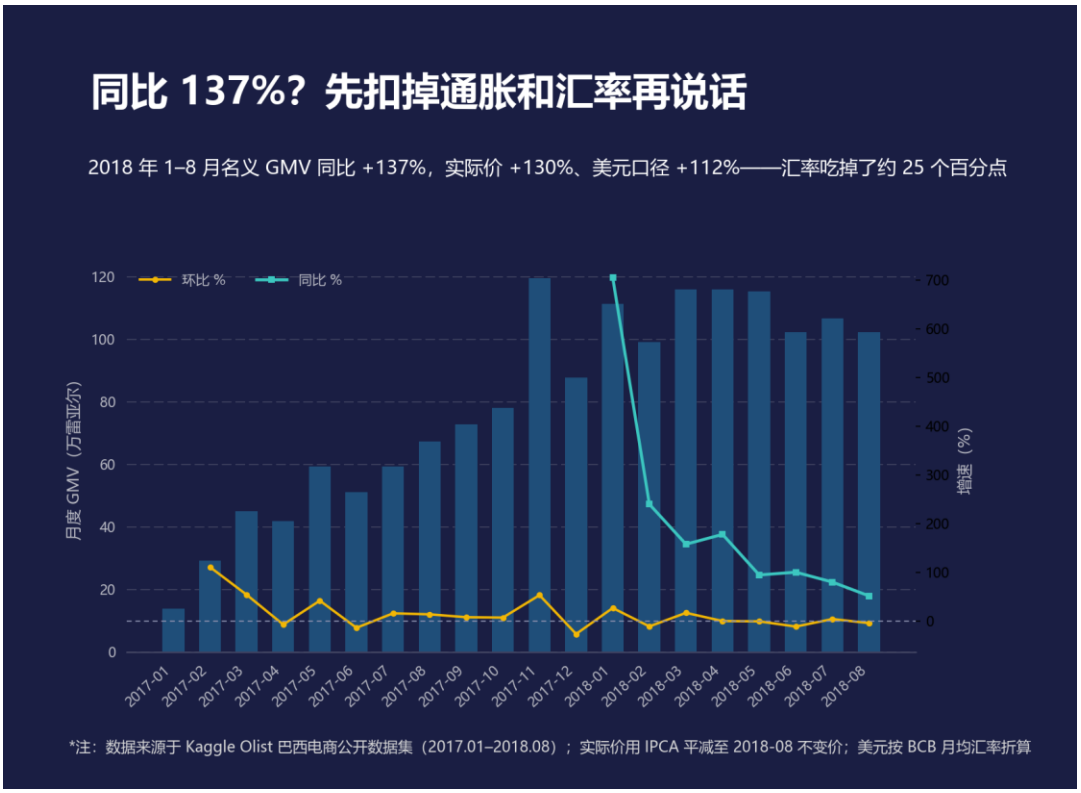


图 5-19　环比/同比与三口径拆解

柱为月度 GMV，黄线环比、青线同比；同比高位但逐月下移，与延迟率抬头时点重合。

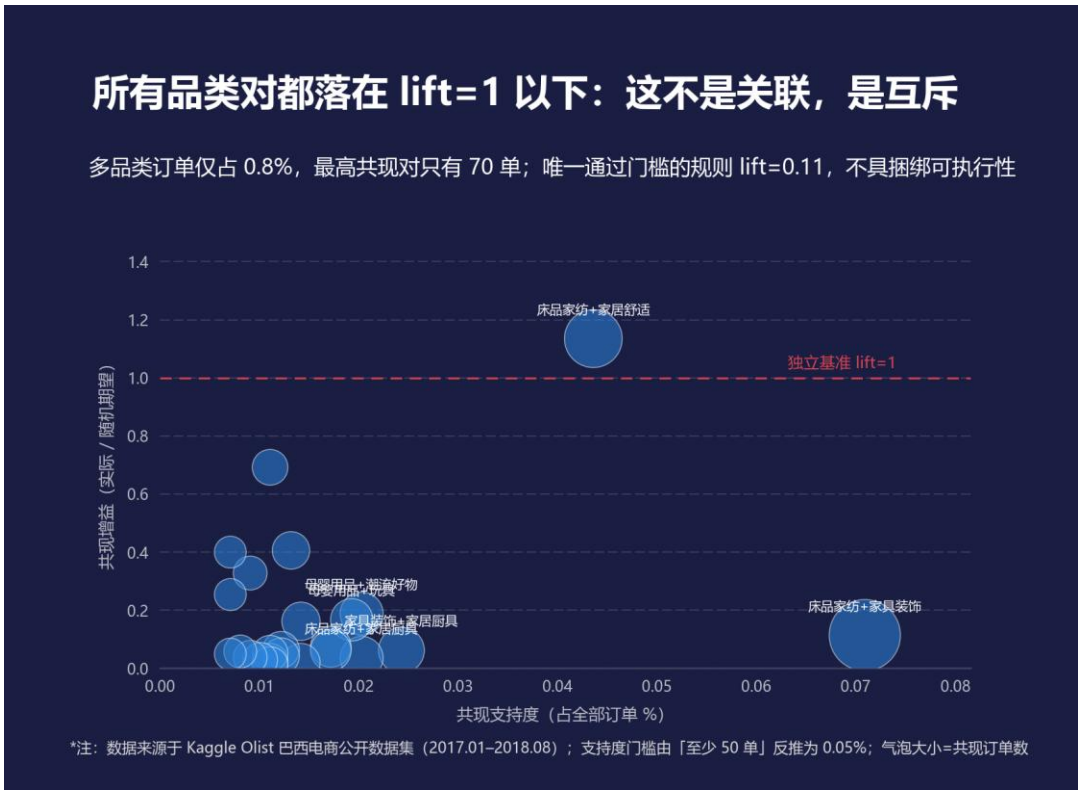


图 5-20　关联规则失效诊断

所有品类对都在 lift=1 以下，共现比随机还少——不是关联，是互斥。

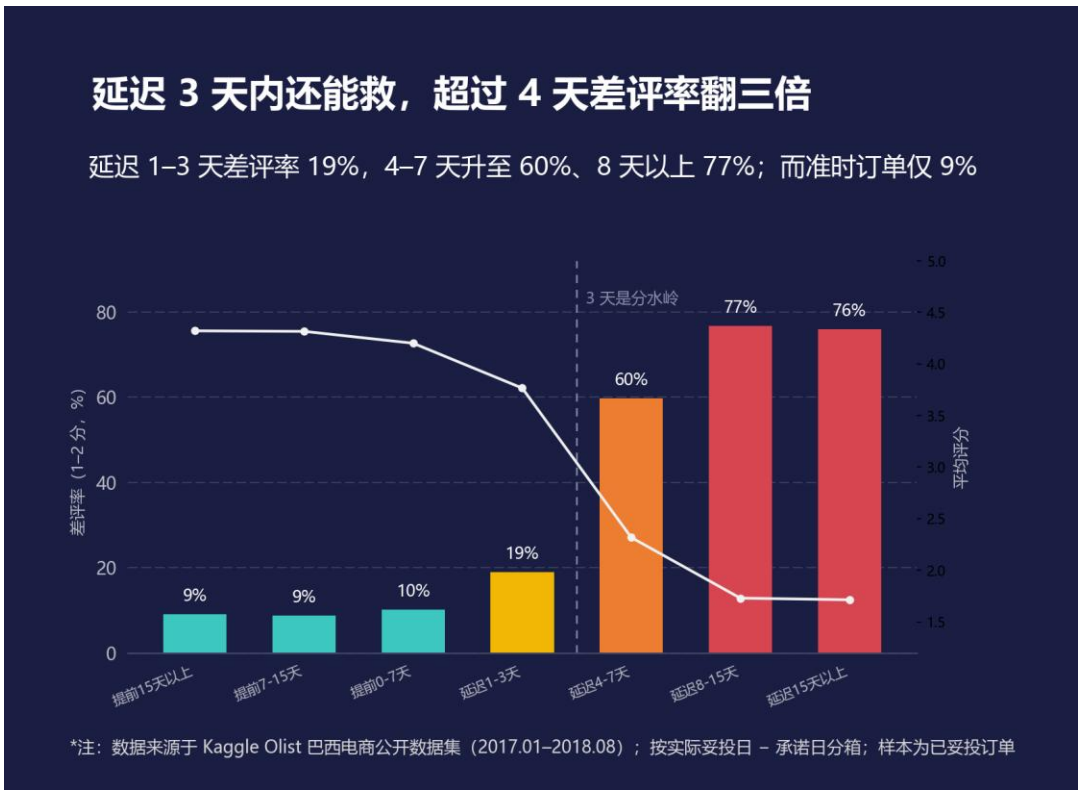


图 5-21　延迟天数与差评率

延迟 1—3 天差评率 19%，4—7 天跳到 60%，3 天是明确的分水岭。

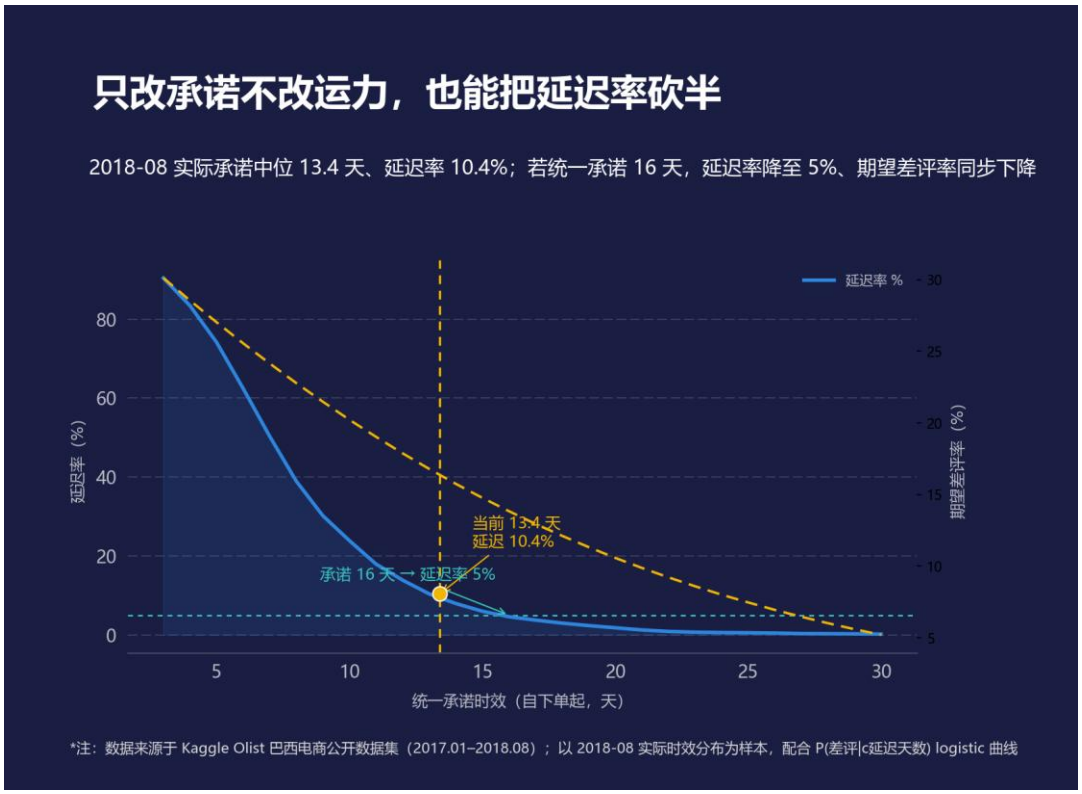


图 5-22　承诺时效反事实曲线

橙线为当前承诺 13.4 天对应的 10.4% 延迟率，右移两天即可降到 6% 附近。

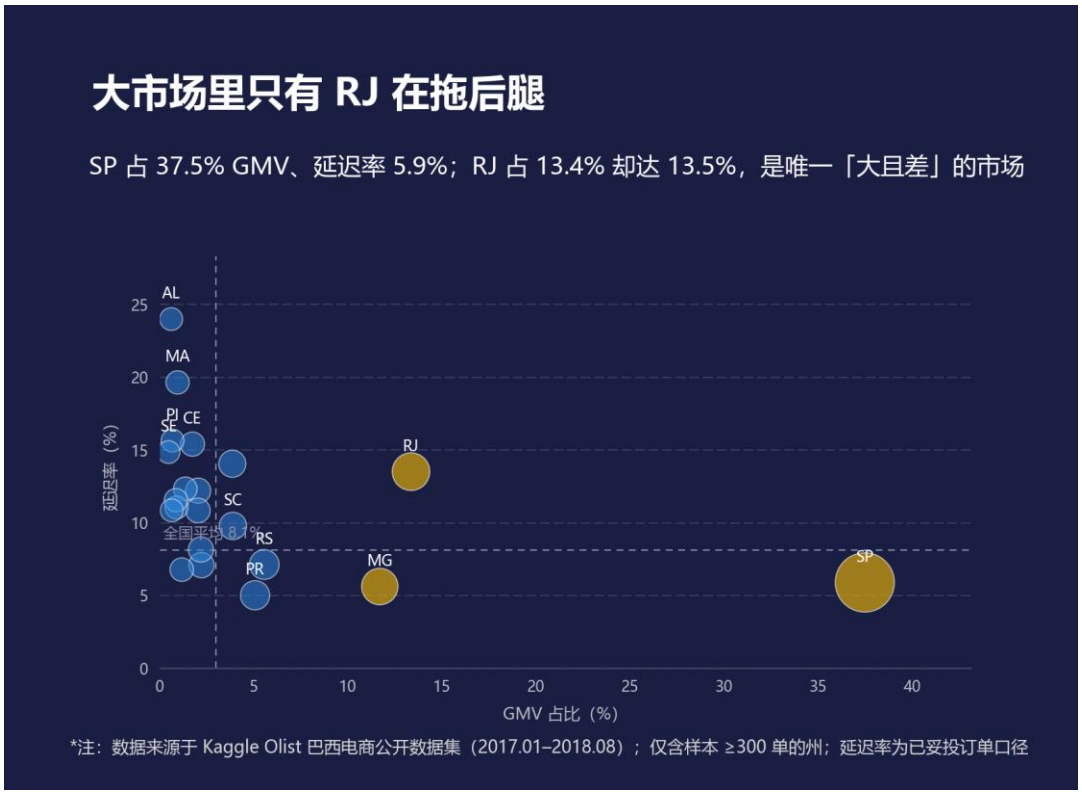


图 5-23　州级市场贡献与履约风险

RJ 是唯一“大且差”的市场：占 13.4% GMV 却延迟 13.5%，优先级最高。

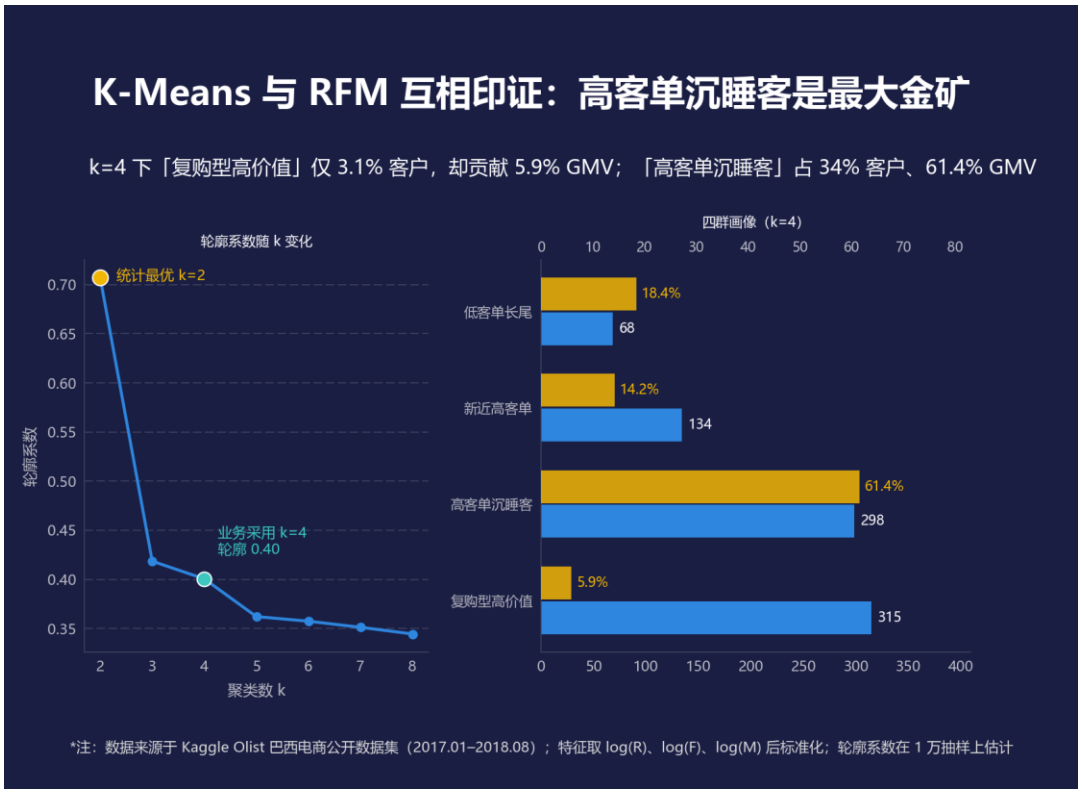


图 5-24　K-Means 分群评估

左图轮廓系数在 k=2 见顶，右图显示 k=4 才分得出可运营的四群——统计与业务的取舍一目了然。

5.4 交互式可视化大屏

大屏采 Python 计算 + 原生 HTML/CSS/JS＋ECharts 实现，ECharts 5.5 内联进 HTML，生成 1.1 MB 自包含文件，双击即可离线打开。共 8 个组件：6 张 KPI 卡、月度成交与增速、州级 GMV 排名、品类结构树图、履约漏斗、RFM 双环、延迟率与评分双轴、州×品类明细表。联动三层：州下拉切换后全部重算；点击州条形等同选中该州；点击品类色块下钻明细表。明细表可排序，延迟率超 10% 的行自动标记“需关注”。



图 5-25　交互式大屏界面（全州视图）

静态图负责“讲一个结论”（副标题即结论），大屏负责“让人自己找结论”，两者共用同一份清洗与聚合逻辑，口径一致。

6 商业案例分析

6.1 案例背景

假设 Olist 在 2018 年 9 月召开季度经营会，议题是“增速放缓下如何守住 GMV”。会前拿到三组矛盾数据：GMV 同比仍 +137%，但环比连降两月；复购率仅 3.11%，但客单价在涨；延迟率升至 10.39%，但平均配送时长其实缩短到 7.0 天。本章用前文模型逐一拆解。

6.2 结果解读

第一组矛盾：增长在换挡而非失速。名义同比中约 25 个百分点来自汇率、7 个百分点来自通胀，真实增长约 112%；环比下滑与承诺时效压到 13 天以内、延迟率抬头的时点高度重合——增速放缓有相当部分是体验恶化传导的结果。

第二组矛盾：客单价上涨来自品类结构而非客户经营。客单价从 152 升至

168 雷亚尔，主要因健康美妆、手表礼品等高单价品类占比提升，而客户侧没有任何改善（M+1 留存 0.49%）。当前增长是“品类驱动”而非“客户驱动”，一旦高单价品类的流量红利见顶将迅速失速。

第三组矛盾：承诺口径收紧快于运力改善。实际时效降 35%，承诺时效却收紧 66%，缓冲被压到 6.1 天后，尾部订单几乎必然击穿承诺。这与剂量反应、反事实曲线共同构成因果链：承诺过紧→延迟率上升→差评率上升→复购进一步走低。

6.3 商业建议

建议一：重标定承诺时效，从“13 天”改为“15—18 天分州设置”。依据：统一承诺 15 天可将延迟率从 10.39% 降至 5.97%，且不增加运力成本；对 AL、MA、PI 等延迟率超 15% 的州单独承诺 21 天。预期延迟率降约 4 个百分点，对应差评率降 2—3 个百分点。

建议二：召回预算从“全量”改为“高客单沉睡客”定向。依据：重要挽留客户 22,235 人，平均沉睡 366 天，人均累计消费 266.9 雷亚尔、为全体均值的 1.6 倍；K-Means 的高客单沉睡客贡献 61.4% GMV。触达时点设在首购后第 45—60 天（复购间隔中位数 64 天的前一档）。

建议三：品类资源按 ABC 分级重分配，并把“跨品类”作为独立目标。依据：A 类 17 个贡献 80%，C 类 25 个仅 5.4%，后者转按需采购；多品类订单客单价是单品类的 1.62 倍而当前仅 0.8% 订单跨品类。因 Apriori 显示品类互斥，捆绑不应基于共现，而应基于同一场景（如新居入伙：床品+家具装饰+厨具）人工设计。

建议四：把“延迟 3 天”设为红线，并据此重设承运商考核。依据：延迟 1—3 天差评率 18.95%、4—7 天 59.7%，阈值明确；且延迟增量的 93% 发生在干线段。建议承运商 KPI 从“平均时效”改为“超 3 天订单占比”，对 AL、MA、PI、CE 四条线路单独议价或更换服务商。

建议五：把“名义 GMV”移出考核，改用实际价与美元双口径。依据：2018 年名义 +137% 而美元口径仅 +112%，相差 25 个百分点；若继续用名义值考核，团队会把汇率波动误读为业绩，进而在雷亚尔回升时误判为“业绩下滑”。

7 结论与展望

7.1 研究结论

增长真实但被高估：剔除通胀与汇率后真实增速约 112% 而非 137%；客户价值高度集中在两类“快要走”的客群，合计贡献 75% GMV；品类组合存在“明星够多、现金牛不足”的缺陷，购物篮在统计上不成立；体验损失的主因是承诺口径而非运力，且存在 3 天的明确阈值。方法上三条经验：阈值必须回到分布本身；模型失效时如实报告比硬凑更有价值；预测必须给区间并说明区间为何这么宽。

7.2 局限性与展望

四点局限：数据仅覆盖 2016-09 至 2018-10 且末两月截断，同期群最长观察 12 个月；缺少投放、流量、库存等内部数据，无法做严格因果推断；F 维度因复购极少而信息量有限；大屏为静态快照。后续可从三方向深化：引入距离与承运商信息把归因细化到线路级；用 Cox 生存分析替代同期群；用承诺时效的分州差异构造准自然实验。

7.3 AI 使用披露

本文在以下环节使用 AI 编程助手（WorkBuddy / Claude 系列）：① 代码脚手架与 matplotlib 版式微调，提示词示例：“按教材模板复现渐变柱形图，画布 1088×794、深蓝底、柱体顶亮底深、副标题写一句话结论”；② 清洗逻辑的异常规则审查，提示词示例：“检查这段清洗逻辑是否有符号陷阱，特别是派生指标为负数时该不该置空”——正是这条提示帮助发现了 delay_days 被误置空的 bug；③ 语言润色。所有模型参数、阈值与结论均由作者依据数据判断并复核，AI 生成内容均经人工验证；代码与结果可通过附录 B 的仓库一键复现。

参考文献

[1] Olist. Brazilian E-Commerce Public Dataset by Olist[DB/OL]. Kaggle, 2018. https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce.

[2] Banco Central do Brasil. Sistema Gerenciador de Séries Temporais (SGS)[DB/OL]. https://api.bcb.gov.br/dados/serie/bcdata.sgs.

[3] Hughes A M. Strategic Database Marketing[M]. 3rd ed. New York: McGraw-Hill, 2005.

[4] Fader P S, Hardie B G S. Customer-Base Analysis in a Discrete-Time NBD/Pareto Model[J]. Marketing Science, 2009, 28(6): 1052-1065.

[5] Agrawal R, Srikant R. Fast Algorithms for Mining Association Rules[C]//Proceedings of the 20th International Conference on Very Large Data Bases. Santiago: VLDB, 1994: 487-499.

[6] Hyndman R J, Athanasopoulos G. Forecasting: Principles and Practice[M]. 3rd ed. Melbourne: OTexts, 2021.

[7] Box G E P, Jenkins G M, Reinsel G C, et al. Time Series Analysis: Forecasting and Control[M]. 5th ed. Hoboken: Wiley, 2015.

[8] Kotler P, Keller K L. Marketing Management[M]. 15th ed. Boston: Pearson, 2016.

[9] 王汉生. 数据思维：从数据分析到商业价值[M]. 北京：中国人民大学出版社, 2017.

[10] 陈为, 沈则潜, 陶煜波. 数据可视化[M]. 2 版. 北京：电子工业出版社, 2019.

[11] 阿里云. 天池数据集平台[DB/OL]. https://tianchi.aliyun.com/.

[12] McKinsey & Company. The State of Fashion 2019[R]. New York: McKinsey, 2019.

附录

A 核心代码片段

```
# 02_clean.py —— 履约指标派生（节选）
o[“delivery_days”] = days(o.order_purchase_timestamp,
                      o.order_delivered_customer_date)
o[“delay_days”] = o[“delivery_days”] - o[“estimated_days”]   # >0 即超时
o[“is_late”] = (o[“delay_days”] > 0).astype(“Int64”)

# 03_analysis_rfm.py —— F 维度为何不用中位数（节选）
# 本数据 F 中位数 = 1、P90 = 1，96.9% 客户只买过一次；
# 若按中位数二分，全部客户都会落入低 F，八分类退化为四分类。
g[“F_flag”] = np.where(g.frequency >= 2, “高”, “低”)

# 03_analysis_forecast.py —— 带置信区间的 SARIMA（节选）
```

```
model = SARIMAX(train, order=(2,1,2), seasonal_order=(0,1,1,13),
              enforce_stationarity=False).fit(disp=False)
fc = model.get_forecast(steps=8); ci = fc.conf_int(alpha=0.05)
```

B 仓库链接与目录结构

公开仓库：https://github.com/fjerry19980101-create/shujukeshihua

```
shujukeshihua/
├── data/raw | clean | raw_aux      原始、清洗后数据与溯源清单
├── scripts/                       01_load → 06_paper 全链路脚本
├── 代码/                          fig01–fig24 每图一份独立脚本 + _style.py
├── outputs/figures | tables | dashboard
├── docs/                          本论文、合规声明、图表索引
├── requirements.txt  run_all.py  README.md
```

C 图表索引

表 A-1　图表索引（图 5-1 至图 5-25）

编号	文件	类型	对应模型
图 5-1	fig01_品类 GMV 六强_渐变柱形图.png	模板复现	—
图 5-2	fig02_各州客单价对比_带均值柱形图.png	模板复现	—
图 5-3	fig03_头部卖家 GMV_渐变圆角柱形图.png	模板复现	集中度
图 5-4	fig04_月度订单量_标注柱形图.png	模板复现	趋势
图 5-5	fig05_支付方式结构_层叠柱形图.png	模板复现	结构占比
图 5-6	fig06_各州准时与延迟_蝴蝶图.png	模板复现	履约对比
图 5-7	fig07_同比对比_对比柱形图.png	模板复现	同比
图 5-8	fig08_订单状态构成_数值百分比.png	模板复现	漏斗
图 5-9	fig09_各州履约时长_甘特图.png	模板复现	延迟归因
图 5-10	fig10_周 GMV 趋势_平滑折线图.png	模板复现	时间序列
图 5-11	fig11_准时交付率_单值圆环图.png	模板复现	履约 KPI
图 5-12	fig12_RFM 八客群 GMV 贡献_玉玦图.png	模板复现	RFM
图 5-13	fig13_品类帕累托 ABC_帕累托图.png	业务模型	帕累托/ABC
图 5-14	fig14_品类组合_波士顿矩阵.png	业务模型	波士顿矩阵
图 5-15	fig15_同期群留存_热力图.png	业务模型	同期群
图 5-16	fig16_RFM 八客群气泡图.png	业务模型	RFM
图 5-17	fig17_SARIMA 预测_置信区间图.png	业务模型	SARIMA
图 5-18	fig18_履约漏斗_漏斗图.png	业务模型	漏斗
图 5-19	fig19_环比同比_组合图.png	业务模型	环比/同比
图 5-20	fig20_关联规则失效诊断_散点图.png	业务模型	Apriori
图 5-21	fig21_延迟与差评_剂量反应图.png	业务模型	延迟归因
图 5-22	fig22_承诺时效反事实_曲线图.png	业务模型	反事实模拟
图 5-23	fig23_州级市场与履约_四象限.png	业务模型	地理分层
图 5-24	fig24_KMeans 分群评估_双面板.png	业务模型	K-Means
图 5-25	dashboard_preview.png	交互大屏	全模型综合